مشروع مقرر برمجة خاصة بعلم البيانات

Programming for Data Science | DPD601

تحليل التجارة الإلكترونية والتنبؤ بتأخر تسليم الطلبات

كلية هندسة المعلوماتية

مدرّسة المقرر الدكتورة دعاء قرضاب

حجم الفريق: خمسة طلاب

موعد التسليم : 2026/11/16

وصف المشروع

يهدف المشروع إلى بناء منظومة برمجية متكاملة لتحليل بيانات تجارة إلكترونية حقيقية، وفهم العوامل المرتبطة بتأخر التسليم، وبناء نماذج تتنبأ باحتمال التأخر عند اعتماد الطلب. ينفذ الطلاب مراحل فهم البيانات وتنظيفها وربطها وتحليلها وتمثيلها بصرياً، ثم بناء النماذج وتقييمها وتفسير نتائجها.

يعتمد المشروع على عدة جداول مترابطة، وتكون وحدة التنبؤ طلباً واحداً. يجب أن يعكس التسليم عملاً جماعياً متكاملاً، مع قدرة كل طالب على شرح جميع مكونات المشروع.

الأدوات المطلوبة

Python | NumPy | Pandas | Matplotlib / Seaborn | Scikit-Learn | Git

يجب إظهار استخدام فعلي للمكتبات المطلوبة ضمن مشروع منظم. الواجهة الرسومية اختيارية، ولا تعوض نقص التحليل أو البرمجة أو التقييم.

المخرجات التعليمية

- تصميم معالجة قابلة لإعادة التشغيل لبيانات متعددة الجداول.
- استخراج مؤشرات وخصائص مفيدة مع منع تسرب المعلومات.
- مقارنة نماذج تنبؤ وتفسير أخطائها، وتوثيق العمل والمساهمات الفردية.

١- البيانات المعتمدة وفهمها

تستخدم جميع الفرق حزمة البيانات التالية حصراً. تضم الحزمة سبعة جداول أصلية من بيانات التجارة الإلكترونية البرازيلية، إضافة إلى دليل عربي وقاموس للأعمدة وملخص تدقيق. لا تستبدل البيانات ببيانات مولدة أو بمجموعة أخرى.

Ecommerce_Delivery_Project_Data.zip

Brazilian E-Commerce Public Dataset by Olist

الجدول	عدد السجلات	المحتوى
الطلبات	99,441	حالة الطلب والتواريخ المرتبطة به
العملاء	99,441	معرفات العملاء ومواقعهم الإدارية
عناصر الطلبات	112,650	المنتجات والبائعون والأسعار والشحن
المدفوعات	103,886	طرق الدفع والقيم والأقساط
المنتجات	32,951	الفئات والخصائص الوصفية
البائعون	3,095	معرفات البائعين ومواقعهم
ترجمة فئات المنتجات	71	أسماء الفئات بالبرتغالية والإنجليزية

• تحديد معنى كل جدول، ومفاتيحه، والعلاقات بينه وبين بقية الجداول، وتقديم مخطط واضح للعلاقات.

• توضيح الفرق بين معرف سجل العميل ومعرف العميل الفريد، وبين الطلب وعنصر الطلب وسجل الدفع.

• توثيق عدد الصفوف والأعمدة وأنواع البيانات والقيم المفقودة في كل جدول قبل المعالجة وبعدها.

المصدر والترخيص

ينسب الطلاب البيانات إلى الجهة الناشرة، ويذكرون المصدر والترخيص في التقرير وملف تعليمات التشغيل. البيانات تاريخية من البرازيل، ولا تعمم النتائج مباشرة على أسواق أخرى.

Olist, & Sionek, A. (2018). Brazilian E-Commerce Public Dataset by Olist. Kaggle.

https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

License: CC BY-NC-SA 4.0

يراعى الإسناد والاستخدام غير التجاري ومشاركة التعديلات وفق الترخيص نفسه. تحفظ البيانات الخام دون تعديل، وتنتج الملفات المعالجة برمجياً.

(استخدم الرابط أعلاه لتحميل البيانات المطلوبة)

٢ تنظيف البيانات ودمجها وهندسة الخصائص

• فحص القيم المفقودة والتكرارات والقيم غير المنطقية، واختيار المعالجة المناسبة مع تبريرها. لا تحذف السجلات أو تعوض القيم دون توثيق.

• تحويل التواريخ والأنواع العددية عند الحاجة، وحفظ بادئات الرموز البريدية كنصوص، والتحقق من ترتيب الأحداث الزمنية.

• اختبار تفرد المفاتيح وسلامة العلاقات، وبيان أثر كل عملية ربط على عدد السجلات.

• تجميع عناصر الطلب وسجلات الدفع كل على حدة إلى مستوى الطلب قبل دمجهما، لتجنب تكرار الصفوف والمبالغ بسبب الربط المتعدد.

لا يعد تكرار معرف الطلب وحده في جدول العناصر أو المدفوعات تكراراً خاطئاً؛ فقد يحتوي الطلب على عدة عناصر أو سجلات دفع صحيحة.

هندسة الخصائص

إنشاء ثماني خصائص مشتقة على الأقل، مع جدول يوضح اسم كل خاصية، وطريقة حسابها، ومصدرها، وسبب ملاءمتها ووقت إتاحتها. يجب أن تشمل خصائص زمنية وعددية وفئوية أو مشتقة من العلاقات.

أمثلة مناسبة هي عدد عناصر الطلب، وعدد البائعين، وإجمالي السعر والشحن، وخصائص أوزان المنتجات، ويوم اعتماد الطلب، والمدة المخططة للتسليم، وتطابق ولاية البائع والعميل. يجب التعامل صراحة مع الطلبات متعددة البائعين.

الاستخدام المطلوب للمكتبات

NumPy

استخدام ثلاث عمليات عددية ذات معنى على الأقل، مثل الأقنعة المنطقية، والحسابات المتجهة، والإحصاءات أو التحويلات العددية. يشرح التقرير لماذا استخدمت هذه العمليات؛ لا يكفي استيراد المكتبة.

Pandas

إظهار القراءة والفحص والاختيار والتصفية ومعالجة القيم المفقودة والربط والتجميع والجداول المحورية والتعامل مع التواريخ. ترفق نتائج تحقق تثبت أن جدول النمذجة يحتوي على صف واحد لكل طلب.

الاختبارات المطلوبة

إضافة اختبارات آلية للمفاتيح، وعدم تضاعف الطلبات بعد الربط، وصحة المجاميع، وصحة تعريف الهدف، واستبعاد الحقول المحظورة. تتضمن اختبارات الهدف حالة تسليم خلال اليوم المتوقع وحالة بعده وحالة تاريخ مفقود.

٣- التحليل الاستكشافي والتمثيل البياني

يجيب كل فريق عن ستة أسئلة تحليلية على الأقل، تربط بين خصائص الطلبات وأداء التسليم. تصاغ الأسئلة بوضوح، وتدعم الإجابات بجداول ورسوم وتفسير يتجاوز وصف الألوان أو الأعداد.

- كيف تتغير أعداد الطلبات ونسبة التأخر عبر الزمن؟
- هل ترتبط المسارات بين الولايات أو تعدد البائعين باختلاف التأخر؟
- كيف تختلف نسبة التأخر باختلاف فئات المنتجات أو حجم الطلب؟
- ما العلاقة بين المدة المخططة للتسليم والتأخر الفعلي؟
- ما أثر القيم المفقودة والاستبعادات على تمثيل البيانات؟
- ما الأنماط التي تستحق المتابعة، وما حدود تفسيرها؟

متطلبات الرسوم

إعداد ثمانية رسوم مفيدة على الأقل، موزعة على خمسة أنواع مختلفة على الأقل. يمكن استخدام المدرجات التكرارية، والأعمدة، والصناديق، والتشتت، والخرائط الحرارية، والمنحنيات الزمنية والرسوم الفرعية.

- لكل رسم عنوان واضح وتسميات للمحاور ووحدات عند الحاجة، وشرح قصير للنتيجة ودلالتها وحدودها.
- عرض نسبة التأخر مع حجم العينة عند مقارنة المجموعات، وعدم ترتيب المجموعات الصغيرة على أنها الأفضل أو الأسوأ دون تنبيه.
- إظهار توزيع الفئة المستهدفة ومناقشة عدم التوازن، وإدراج تحليل زمني وتحليل للعلاقات بين المتغيرات.
- عدم تفسير الارتباط على أنه علاقة سببية؛ توضح النتائج ما يظهر في البيانات فقط.

توثيق قرارات التحليل

يحدد الفريق المجتمع الذي يحلله في كل شكل. فالتحليل العام للطلبات قد يشمل حالات متعددة، بينما تحليل هدف التأخر يقتصر على الطلبات المؤهلة ذات التواريخ الصالحة. لا تخلط المقامات بين المقارنات.

يجوز استخدام نتائج التسليم الفعلية في التحليل الوصفي وتحديد الهدف، لكنها لا تصبح بذلك مدخلات مسموحة لنموذج التنبؤ.

٤- بناء النماذج وتقييمها

السيناريو المعتمد هو التنبؤ عند اعتماد الطلب، مع افتراض دراسي معلن لإتاحة تفاصيل العناصر والدفع وموعد التسليم المتوقع في تلك اللحظة. لا توثق النسخة التاريخية لحظة إتاحة جميع الحقول، ولذلك يجب ذكر هذا القيد في التقرير.

تعريف المتغير المستهدف

تعد قيمة الهدف واحداً إذا وقع التسليم الفعلي للعميل في يوم لاحق ليوم التسليم المتوقع، وصفراً إذا وقع في اليوم المتوقع أو قبله. تقارن أجزاء التاريخ بعد التحقق من صلاحيتها، وليس الوقت مع منتصف الليل.

Target: is_late

تستخدم الطلبات المسلمة ذات تاريخي التسليم المتوقع والفعلي الصالحين. لا تحول الطلبات الملغاة أو غير المسلمة أو مجهولة النتيجة إلى فئة التسليم في الموعد. يستبعد تاريخ الشراء أو الاعتماد غير الصالح عند إعداد نموذج لحظة الاعتماد، وتوثق الأعداد وأسباب الاستبعاد.

منع تسرب المعلومات

تستبعد من المدخلات حالة الطلب النهائية، وتاريخ تسليمه الفعلي للعميل أو لشركة الشحن، ومدة التسليم الفعلية، ومقدار التأخر وأي نتائج لاحقة. تستخدم المعرفات للربط والتتبع فقط. لا يستخدم موعد تسليم العنصر للشحن في النموذج الأساسي دون تبرير إتاحته وقت التنبؤ.

Exclude: order_status | order_delivered_customer_date | order_delivered_carrier_date

أي إحصاء تاريخي للبائع أو العميل يعتمد على معلومات سابقة متاحة فقط. تضبط معالجة القيم المفقودة والترميز والتحجيم على بيانات التدريب وحدها، ثم تطبق على بقية الأجزاء.

خطة التجريب والمقارنة

• تقسيم زمني إلى تدريب وتحقق واختبار نهائي وفق وقت اعتماد الطلب، مع ذكر الحدود الزمنية والأعداد. تحفظ الفترة الأحدث للاختبار.

• إنشاء نموذج مرجعي بسيط، ثم تدريب نموذجين مختلفين على الأقل باستخدام المكتبة المطلوبة، وضبط إعداداتهما على التدريب والتحقق فقط.

• استخدام التقسيم نفسه للمقارنة، مع ثبات البذور العشوائية عند الحاجة. لا تستخدم الاختبار النهائي لاختيار الخصائص أو العتبة أو الإعدادات.

• عرض الدقة والإحكام والاستدعاء ودرجة التوازن للفئة المتأخرة ومصفوفة الالتباس. عند توفر درجات احتمالية يعرض متوسط الإحكام أيضاً، ولا تكفي الدقة وحدها.

Accuracy | Precision | Recall | F1-score | Confusion Matrix | Average Precision

• تفسير الإيجابيات والسلبيات الكاذبة، وتحليل الأخطاء، واختيار النموذج الأنسب بتبرير. يمكن أن تظهر المقارنة النهائية تفوق النموذج المرجعي؛ لا تعدل النتائج لإخفاء ذلك.

٥- التشاركية والتسليمات المطلوبة

ينفذ المشروع في فريق من طالبين إلى خمسة طلاب. توزع المسؤوليات الآتية بحسب حجم الفريق؛ وعند اكتماله بخمسة طلاب تسند مسؤولية أساسية لكل عضو، مع مراجعة متبادلة للكود وفهم جميع الأجزاء.

المسؤولية	المخرج الأساسي
جودة البيانات	تدقيق وتنظيف وسجل قرارات
العلاقات والخصائص	دمج صحيح وقاموس للخصائص
التحليل والرسوم	أسئلة وجداول ورسوم مفسرة
النماذج والتقييم	مقارنة تجارب وتحليل أخطاء
التكامل والاختبارات	تشغيل موحد واختبارات وتوثيق

يستخدم مستودع مشترك لإدارة الإصدارات، مع مساهمات فعلية ومراجعة واحدة موثقة على الأقل لكود زميل لكل طالب. لا يكفي عدد التعديلات وحده لإثبات المساهمة. يرفق جدول بالأعمال المنفذة وأصحابها والمراجعين.

Git repository | Commit history | Code review

التسليمات

- مجلد مشروع كامل يحوي ملفات برمجية منظمة بأسماء واضحة، والبيانات الخام المعتمدة أو الحزمة الأصلية، وآلية إنتاج البيانات المعالجة.
- تقرير نهائي بصيغة وورد أو بي دي إف يضم عنوان المشروع وأسماء الطلاب وأرقامهم، والمقدمة ووصف البيانات، والمعالجة والخصائص، والتحليل والرسوم، والنماذج والتقييم، والاستنتاجات والقيود والمراجع والمساهمات.
- ملف تعليمات تشغيل يبين الأدوات والإصدارات وبنية المجلدات وخطوات الإعداد والتشغيل وإعادة إنتاج النتائج، مع ملف للاعتماديات.

README.md | requirements.txt

- مجلد للرسوم والنتائج، واختبارات قابلة للتشغيل، وسجل مختصر للتجارب وإعداداتها ومقاييسها.

٦- توزيع الدرجات وقواعد المشروع

تحفظ أوزان التقييم الواردة في النموذج السابق. تقيم التشاركية والاختبارات ضمن جودة المشروع، وتتحقق المناقشة من الفهم الفردي؛ ولا يفترض تساوي درجات الأعضاء عند اختلاف المساهمة أو الفهم.

محور التقييم	الدرجة	شواهد التقييم
بنية المشروع وجودة الكود	15	التنظيم والاختبارات والتكامل وإدارة الإصدارات
تنظيف البيانات ومعالجتها	20	تدقيق موثق وربط صحيح ومعالجة مبررة
استخدام المكتبات العددية والجدولية	15	عمليات عددية فعلية وربط وتجميع وخصائص
التحليل والتفسير	15	إجابات مدعومة وقراءة نقدية وحدود واضحة
التصور البياني	10	تنوع الرسوم وصحتها ووضوح تفسيرها
نماذج التعلم الآلي وتقييمها	15	مرجع ونموذجان وتقسيم زمني ومنع التسرب
التقرير والعرض والمناقشة	10	اكتمال التوثيق ووضوح العرض والفهم الفردي
المجموع	100	

القواعد الملزمة

- لا يقبل مشروع يعتمد على دفتر تفاعلي وحده دون بنية واضحة وملفات برمجية منظمة.
- لا يكفي نموذج تعلم آلي واحد. يلزم نموذج مرجعي ونموذجان مختلفان على الأقل للمقارنة.
- لا تقبل الرسوم دون تفسير، ولا تعد النتائج غير القابلة لإعادة الإنتاج تسليماً مكتملًا.
- يعامل التشابه بين المشاريع بوصفه مخالفة أكاديمية، وتمنح المجموعة المخالفة درجة واحدة مباشرة. لا يقصد بذلك التشابه الطبيعي الناتج عن البيانات الموحدة أو المتطلبات المشتركة.
- يجب أن يستطيع كل طالب شرح جميع أجزاء المشروع، وأن تميز المراجع بوضوح عن العمل المنجز داخل الفريق.