تحليل التجارة الإلكترونية والتنبؤ بتأخر تسليم الطلبات

مشروع مقرر البرمجة الخاصة بعلم البيانات F25 DPD601

كلية هندسة المعلوماتية

مدرسة المقرر الدكتورة دعاء قرضاب

موعد التسليم وفق التكليف 16 تشرين الثاني 2026

بيانات الفريق

الشعبة C1

الطالب والرقم الجامعي	مسؤوليات العمل
مهند الشعار (Mohanad Alshaar) mohanad_118315	تكامل المشروع وتشغيله على Windows، إدارة Git وتجهيز بيئة التشغيل.
بيان علي (Bayan Ali) bayan_117286	تجهيز البيانات وتنظيفها والتحليل الاستكشافي وإعداد الرسوم.
مازن اليافي (Mazen Alyafi) mazen_216443	بناء النماذج ومقارنتها زمنياً وتقييم أدائها وتحليل الأخطاء.
محمد القصير (Muhammad Al-Qasir) Muhammad_172653	إعداد التقرير والتوثيق ومراجعة الاختبارات وتجهيز المناقشة.

فكرة المشروع وأهم ما وصلنا إليه

تضم البيانات الأصلية سبعة جداول مرتبطة، تحتوي على 99,441 طلبًا. وبعد تدقيق الحالات والتواريخ أمكن تحديد نتيجة التسليم لعدد 96,394 طلبًا، تأخر منها 6,532 طلبًا، أي بنسبة 6.78%. بنينا جدولًا موحدًا على مستوى الطلب، ثم جرّبنا نماذج تتنبأ باحتمال تأخره باستخدام المعلومات المفترض توافرها عند الاعتماد.

اعتمادًا على متوسط الأداء في فترات التحقق الزمنية، اخترنا النموذج LogisticLog_C1_plain. وفي فترة التقييم الأحدث بلغت قيمة الاستدعاء 53.83%، والإحكام 9.44%، وبلغ مقياس F1 نحو 0.1606. تحسن ترتيب الطلبات المعرضة للتأخر، لكن الإنذارات الخاطئة بقيت كثيرة. ولأن نتائج هذه الفترة كانت قد فُحصت أثناء التطوير السابق، نتعامل معها كتقييم تاريخي لا كاختبار مستقل جديد.

ما الذي حاولنا معرفته

سؤالنا كان بسيطاً: هل يمكن تقدير خطر التأخر بمجرد اعتماد الطلب؟ للإجابة فحصنا الجداول وتأكدنا من طريقة ربطها، ثم درسنا الفروق بين الطلبات المتأخرة وغيرها. وأخيراً قارنا عدة نماذج على فترات زمنية متتابعة، ووضعنا إلى جانبها نموذجاً مرجعياً بسيطاً حتى لا نبالغ في قيمة أي تحسن.

المصدر هو جداول Olist السبعة المطلوبة في التكليف، من الحزمة الأصلية المرفقة. لم نضف طلبات مصطنعة أو ملفات المراجعات والمواقع الإضافية. البيانات تاريخية من البرازيل، والمبالغ بالريال البرازيلي BRL، والأوقات كما سجلت دون تحويل غير موثق [1، 2].

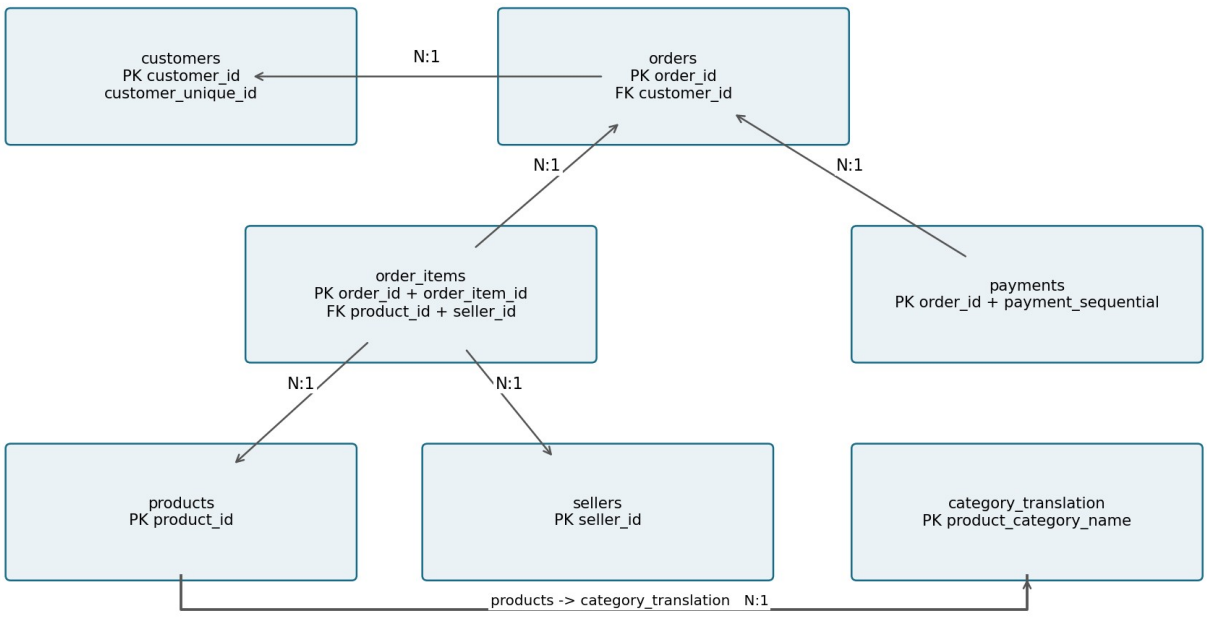
الأسئلة التي بدأنا منها

• كيف تغير حجم الطلبات ونسبة التأخر عبر الزمن؟
• هل كان موعد التسليم المتوقع مناسباً للمدة الفعلية؟
• كيف اختلف التأخر بين المسارات داخل الولاية وخارجها؟
• كيف اختلفت الولايات مع مراعاة حجم كل عينة؟
• هل ظهرت فروق حسب فئة المنتج وحجم الطلب؟
• ما الذي ظهر في الطلبات متعددة البائعين؟
• ما أثر النواقص والاستبعادات في المجتمع الذي نمثله؟
• أي معلومات أفادت النماذج، وأين تركزت أخطاؤها؟

كيف استخدمنا الأدوات

استخدمنا Pandas للقراءة والفحص والتواريخ والتجميع والربط، وNumPy للحسابات المتجهة وإعادة المعاينة. أنشأنا الرسوم باستخدام Matplotlib وSeaborn، واستخدمنا Scikit-Learn للمعالجة والتدريب والتقييم. أضفنا اختبارات آلية وملف إعدادات وسجل تجارب. يحفظ Git إصدارات الشفرة وتغييراتها.

كيف ترتبط الملفات ببعضها



الجدول	الصفوف	الأعمدة	المفتاح
orders	99,441	8	order_id
customers	99,441	5	customer_id
items	112,650	7	order_id + order_item_id

الجدول	الصفوف	الأعمدة	المفتاح
payments	103,886	5	order_id + payment_sequential
products	32,951	9	product_id
sellers	3,095	4	seller_id
translation	71	2	product_category_name

customer_id يخص سجل العميل المرتبط بالطلب، بينما customer_unique_id يربط الشخص نفسه عبر مشتريات متعددة. لدينا 96,096 عميلاً فريداً مقابل 99,441 سجل عميل. وقد يضم الطلب عدة عناصر وعدة دفعات، لذلك تكرار رقمه في هذين الملفين طبيعي. تستخدم المعرّفات للربط والتتبع فقط، ولا تدخل التنبؤ.

ما الذي احتاج إلى تنظيف

الجدول	الصفوف	نواقص قبل	نواقص بعد	صفوف متطابقة
orders	99,441	4,908	4,908	0
customers	99,441	0	0	0
items	112,650	0	0	0
payments	103,886	0	0	0
products	32,951	2,448	2,452	0
sellers	3,095	0	0	0
translation	71	0	0	0

الجدول يحصي الخلايا الفارغة لا عدد الطلبات المتأثرة لا توجد صفوف متطابقة أو مفاتيح أساسية مكررة. لم نحذف صفوفاً من الملفات الخام، وحفظنا بصمة لكل ملف. أما نوع كل عمود ونسبة النقص فيه قبل المعالجة وبعدها فموجودان في column_audit.csv.

قرأنا بادئات الرموز البريدية كنصوص حتى لا تضيع الأصفار في بدايتها. لم تظهر تواريخ غير قابلة للتحويل، لكن بعض الخانات كانت فارغة أصلاً: 160 تاريخ اعتماد، و2,965 تاريخ وصول للعميل، و1,783 تاريخ تسليم للناقل. وفي جدول المنتجات وجدنا 610 قيماً مفقودة في الفئة وبعض الأوصاف، وقيمتين مفقودتين في كل قياس فيزيائي أصلي. كما اعتبرنا أربعة أوزان مسجلة بالصفر قياسات غير معروفة.

الفئة المفقودة أصبحت unknown، والفئة غير المترجمة بقيت باسمها البرتغالي؛ شملت الأخيرة 13 منتجاً. لم نحذف المبالغ الكبيرة لمجرد كبرها، ولم نجد مبالغ أو أقساطاً سالبة. النواقص العددية للمدخلات تعوض من وسيط التدريب فقط. تواريخ التسليم لا تعوض لأن ذلك سيختلق النتيجة.

وجدنا 61 وصولاً للعميل قبل الاعتماد، و1,359 تسليماً للناقل قبل الاعتماد، و23 وصولاً قبل الناقل. سجلنا الحالات دون تخمين ترتيب بديل. استبعدنا ما يمنع تعريف نموذج الاعتماد بوضوح؛ تاريخ الناقل بقي للتدقيق فقط. البيانات لا تتضمن سجلاً كاملاً لتغير الحالات، وهذا قيد مهم.

كيف حددنا التأخر وربطنا الطلبات

عرّفنا الطلب المتأخر بأنه الطلب الذي وصل بعد اليوم المحدد للتسليم. أما إذا وصل في اليوم المتوقع نفسه، حتى في ساعاته الأخيرة، فاعتبرناه في الموعد. لم نضع الطلبات الملغاة أو غير المسلمة أو مجهولة التاريخ ضمن فئة «غير متأخر». ولتفادي العد المكرر أعطينا كل طلب مستبعد سبباً واحداً وفق ترتيب فحوص واضح.

السبب الحصري	الطلبات
eligible	96,394
not_delivered	2,963
delivered_before_approval	61
missing_purchase_or_approval	14
missing_delivery_or_estimate	8
estimate_before_approval_day	1

جمعنا العناصر والمدفوعات منفصلين قبل الربط. مثلاً، ربط ثلاثة عناصر بسجلّي دفع مباشرة ينتج ستة صفوف، فتتكرر المبالغ. التجميع المستقل مع فحص cardinality يمنع ذلك.

الوصل	قبل	بعد	بلا مقابل
customers	99,441	99,441	0
item_aggregates	99,441	99,441	775
payment_aggregates	99,441	99,441	1

بعد ربط الجداول ظل لدينا 99,441 صفاً، أي صف واحد لكل طلب، ولم تتغير مجاميع الأسعار أو الشحن أو المدفوعات مقارنة بالملفات الأصلية. ظهرت 775 حالة لا يقابلها سجل عناصر، وحالة واحدة لا يقابلها سجل دفع. لم نحذفها من الجدول العام؛ بل أضفنا مؤشرات توضّح النقص، واحتفظنا بفروق المبالغ كما هي للمراجعة.

المعلومات التي أخذناها من الطلب والمنتجات

اخترنا 28 خاصية أساسية من بيانات الطلب والعميل والعناصر والدفع. يشرح الجدول التالي مجموعة خصائص المنتجات والبائعين، من عدد العناصر والبائعين إلى الأوزان والفئات. أما القاموس المرفق فيوضح الحساب والمصدر وسبب الاختيار ووقت الإتاحة المفترض لكل خاصية.

الخاصية	الحساب	المصدر
item_count	عدد صفوف العناصر في الطلب	العناصر
seller_count	عدد البائعين المختلفين	العناصر
product_count	عدد المنتجات المختلفة	العناصر
category_count	عدد الفئات بعد معالجة النقص	العناصر + المنتجات + ترجمة الفئات

الخاصية	الحساب	المصدر
main_category	الفئة الأكثر تكراراً والتعادل أبجدي	العناصر + المنتجات + ترجمة الفئات
customer_state	ولاية العميل	العملاء
same_state_share	نسبة العناصر التي يقع بائعها في ولاية العميل	العناصر + البائعون + العملاء
multi_seller	هل شارك أكثر من بائع	العناصر
mean_weight_g	متوسط الأوزان المعروفة	العناصر + المنتجات
max_weight_g	أكبر وزن معروف	العناصر + المنتجات
mean_volume_cm3	متوسط حاصل ضرب أبعاد كل عنصر	العناصر + المنتجات
total_weight_g	مجموع الأوزان المعروفة مع إبقاء المجهول	العناصر + المنتجات
physical_missing_share	نسبة العناصر التي ينقص وزنها أو حجمها	العناصر + المنتجات
total_price	مجموع أسعار العناصر بالريال البرازيلي	العناصر

حفظنا عدد البائعين ونسبة العناصر التي يقع بائعها في ولاية العميل، ولم نأخذ أول بائع ونُهمل الباقين. الفئة الأساسية الأكثر تكراراً والتعادل أبجدي. الوزن والحجم أوصاف من الكتالوج، وقد يكون مجموع الوزن جزئياً إذا غابت بعض القياسات؛ لذلك أضفنا نسبة النقص.

المعلومات التي أخذناها من الدفع والتواريخ

يكمل الجدول التالي خصائص السعر والشحن والدفع ووقت الاعتماد، ومنها عدد الدفعات والمدة المخططة للتسليم. نفترض، كما يسمح التكليف، أن هذه المعلومات متاحة عند الاعتماد؛ لكن السجلات التاريخية لا تثبت لحظة توافر كل حقل بصورة مستقلة. لذلك نذكر هذا الافتراض بوضوح عند تفسير النتائج.

الخاصية	الحساب	المصدر
total_freight	مجموع تكلفة الشحن	العناصر
freight_share	الشحن مقسوماً على سعر موجب وإلا تبقى القيمة مجهولة	العناصر
payment_count	عدد سجلات الدفع	المدفوعات
payment_total	مجموع المدفوعات	المدفوعات
max_installments	أكبر عدد أقساط	المدفوعات
payment_type_count	عدد طرق الدفع المختلفة	المدفوعات
main_payment_type	طريقة الدفع صاحبة أكبر مبلغ والتعادل أبجدي	المدفوعات

الخاصية	الحساب	المصدر
has_items	هل توجد عناصر للطلب	الطلبات + العناصر
has_payments	هل يوجد سجل دفع	الطلبات + المدفوعات
approval_hour	ساعة الاعتماد	الطلبات
approval_weekday	يوم الأسبوع من الاثنين صفر إلى الأحد ستة	الطلبات
approval_month	رقم الشهر من واحد إلى اثني عشر	الطلبات
approval_wait_hours	الساعات بين الشراء والاعتماد	الطلبات
planned_days	الأيام بين يوم الاعتماد والموعد المتوقع	الطلبات

قارنا تمثيلاً خاماً وآخر لوغاريتمياً ودورياً للانحدار اللوجستي. log1p يخفف أثر القيم الموجبة الكبيرة، وsin وcos يمثلان الساعة ويوم الأسبوع والشهر كدورات. التحويلات ثابتة لا تتعلم من الاختبار؛ التعويض والتحجيم بعدها يتعلمان من التدريب فقط. عدد مدخلات الطلب الأصلية يبقى 28 رغم توسع التمثيل الداخلي.

كيف قسمنا البيانات دون حذف الطلبات البطيئة

الجزء	الطلبات	المتأخرة	النسبة	فترة الاعتماد
train	26,550	955	3.60%	2016-09-15 / 2017-10-02
validation	6,991	397	5.68%	2018-01-01 / 2018-01-31
test	25,550	1,124	4.40%	2018-05-01 / 2018-08-29

حددنا فترة كل طلب اعتماداً على تاريخ الموافقة فقط، وتركنا فاصلاً زمنياً ثابتاً قدره 90 يوماً قبل التحقق والاختبار. الهدف هو تجنب اختيار الطلبات بحسب سرعة وصولها؛ فالطلب البطيء ليس صفاً يجوز استبعاده لمجرد أنه لم يصل بعد. طلبات الفواصل بقيت ضمن التحليل العام، لكنها لا تدخل النوافذ المستخدمة لتقييم النماذج.

ثم فحصنا وقت معرفة الهدف: إذا وصل الطلب في موعده، نعرف النتيجة عند وصوله. وإذا انقضى اليوم المتوقع دون وصوله، يصبح متأخراً من بداية اليوم التالي، حتى لو وصل لاحقاً. تعتمد هذه القاعدة على صحة التواريخ المسجلة، والمجتمع يظل مشروطاً بالتسليم النهائي وفق التكليف. إذا وجد طلب لا تعرف نتيجته قبل ساعة التقييم المحددة، يتوقف التشغيل لمراجعة الفترات؛ لا يحذف ذلك الطلب وحده.

في النسخة الأولى، استبعدت الحدود 5,004 طلبات بنسبة تأخر 22.96%، فغيرت تركيب العينة. النسخة الحالية تمنع اختيار الصفوف حسب سرعة الوصول لا يعني ذلك أن المجتمع أصبح ممثلاً لكل الطلبات الممكنة؛ الملغى وغير المحسوم خارج نموذج التأخر، كما أن الفواصل تقلل حجم التدريب المتاح.

أبقينا الحالة النهائية والتسليم الفعلي للعميل والناقل ومدة التسليم ومقدار التأخر وshipping_limit_date وجميع المعرّفات خارج المدخلات لا توجد إحصاءات أداء لبائع أو عميل مبنية على نتائج مستقبلية. التعويض والترميز والتحجيم يتعلمان من التدريب وحده داخل Pipeline.

فترة أيار إلى آب 2018 سبق عرض نتائجها في النسخة الأولى. لذلك نسمي نتائجها الحالية تقييماً تاريخياً خارج زمن التدريب، ولا ندعي أنها تأكيد مستقل جديد. يلزم مصدر زمني جديد لم نشاهده لتقييم مستقل بعد هذه المراجعة.

كيف قارنا النماذج عبر أكثر من فترة

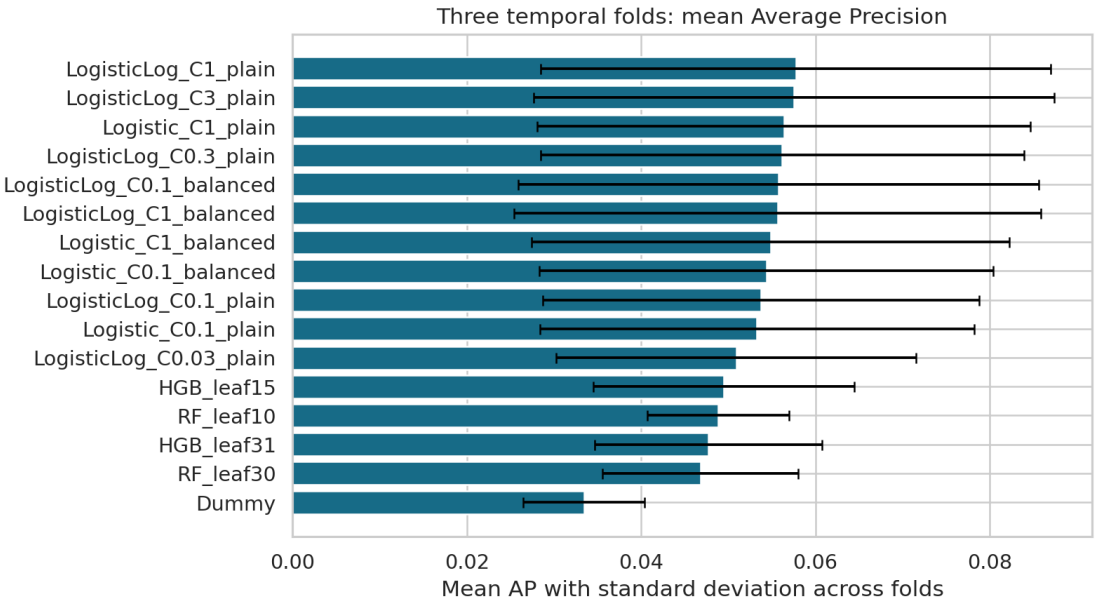
الفترة	تدريب	تحقق	تأخر التدريب	تأخر التحقق
2017-06	2,770	3,143	2.74%	3.02%
2017-08	7,584	4,217	4.52%	2.87%
2017-10	14,315	4,441	3.80%	4.14%

قارنا 16 إعداداً عبر 3 فترات، أي 48 ملاءمة للمقارنة.

كررنا المقارنة على ثلاث فترات، مع تدريب متوسع وفاصل 90 يوماً قبل كل فترة تحقق. فحصنا توفر أهداف التدريب قبل تلك الفترة، وتوفر أهداف المقارنة قبل كانون الثاني 2018. اخترنا أعلى متوسط Precision Average عبر الفترات، لأن هذا المقياس يقيّم ترتيب الخطر دون الارتباط بعتبة واحدة.

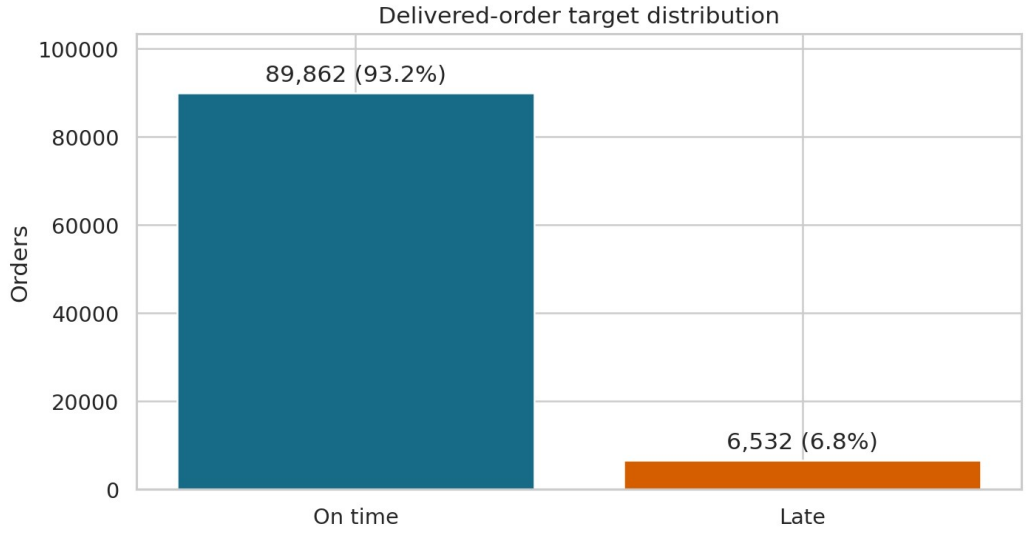
الإعداد	متوسط AP	انحرافه	أقل AP
LogisticLog_C1_plain	0.0577	0.0293	0.0403
LogisticLog_C3_plain	0.0575	0.0298	0.0399
Logistic C 1_plain	0.0564	0.0283	0.0380
LogisticLog_C0.3_plain	0.0562	0.0278	0.0392
LogisticLog_C0.1_balanced	0.0558	0.0299	0.0372
LogisticLog_C1_balanced	0.0557	0.0302	0.0362
Logistic C 1_balanced	0.0549	0.0274	0.0387
Logistic C 0.1_balanced	0.0544	0.0261	0.0384
LogisticLog_C0.1_plain	0.0537	0.0250	0.0382
Logistic C 0.1_plain	0.0533	0.0249	0.0365
LogisticLog_C0.03_plain	0.0509	0.0207	0.0372
HGB_leaf15	0.0495	0.0150	0.0372
RF_leaf10	0.0488	0.0081	0.0406
HGB_leaf31	0.0477	0.0130	0.0373
RF_leaf30	0.0468	0.0112	0.0377
Dummy	0.0335	0.0070	0.0287

حصل LogisticLog_C1_plain على أعلى متوسط في المقارنة الزمنية. جميع الإعدادات ونتائجها محفوظة في temporal_cv_trials.csv، وتوجد حدود الفترات والبذرة 601 في config.json. خلال تطوير النموذج جرّبنا التمثيل اللوغاريتمي والدوري، ثم قيم الانتظام C=0.03 و0.3 و3. أجرينا هذه المقارنات على طيات التدريب والتحقق، ولم نستخدم الفترة النهائية لاختيار الإعداد.

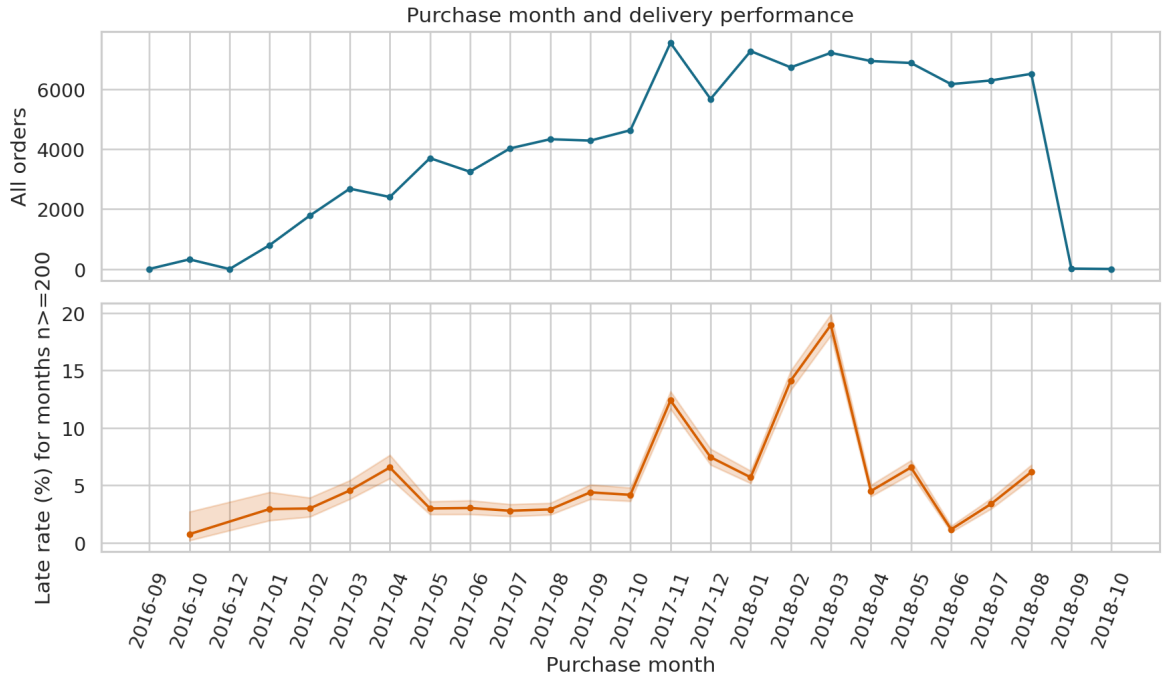


يبين الرسم كيف اختلف متوسط أداء النماذج باختلاف الأشهر المستخدمة للتحقق. لهذا لم نعتمد على فترة واحدة في اختيار الإعداد؛ تفاوت الفترات جزء أساسي من تفسير النتيجة.

كم طلباً تأخر وكيف تغيرت النسبة

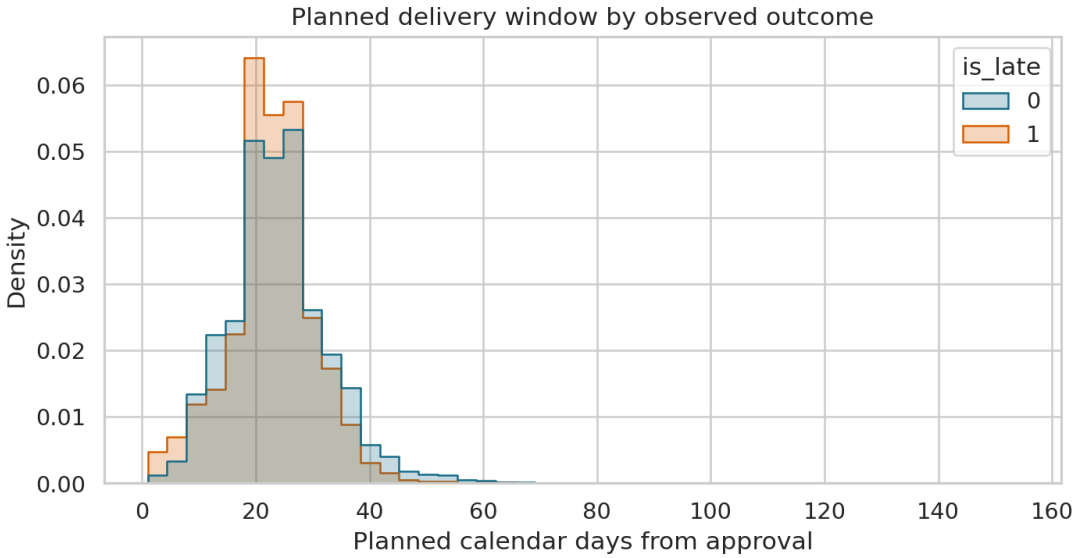


الفئة المتأخرة 6.78% فقط من المجتمع المؤهل. لهذا يمكن أن تبدو الدقة مرتفعة حتى لنموذج لا يكتشف أي متأخر. نقرأ الدقة إلى جانب Precision وRecall وF1 وAP.

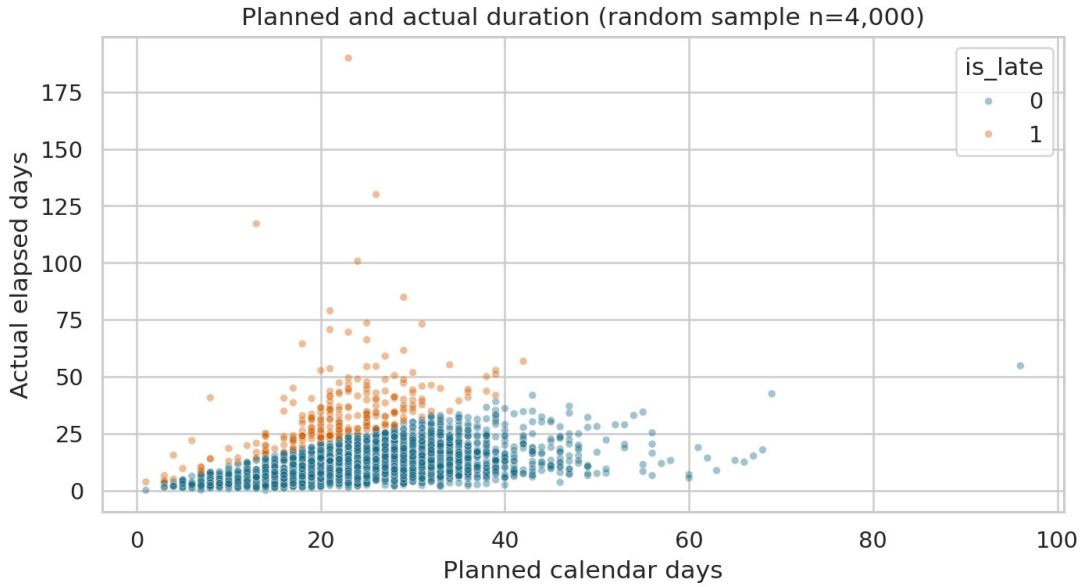


الرسم الأعلى لكل الطلبات والأسفل للمؤهلين فقط. في آذار 2018 تأخر 1,328 من 7,003 طلبات، أي 18.96%، مقابل 5.70% في كانون الثاني لا تشرح البيانات سبب الفرق. يعرض منحنى النسبة الأشهر ذات 200 طلب مؤهل على الأقل حتى لا تطغى العينات الصغيرة على المقارنة. حجم جميع الأشهر ظاهر أعلاه، والأعداد والنطاقات الكاملة محفوظة في الجدول.

هل كان موعد التسليم المتوقع مناسباً



يعرض المدرج شكل مدة الوعد في كل فئة، لا حجم الفئتين النسبي. تأخر 16.00% من الطلبات ذات وعد سبعة أيام أو أقل، مقابل 4.84% لما تجاوز 30 يوماً. هذه ملاحظة تستحق مراجعة الوعود القصيرة، وليست دليلاً على أن تمديد الموعد وحده سيحل المشكلة.

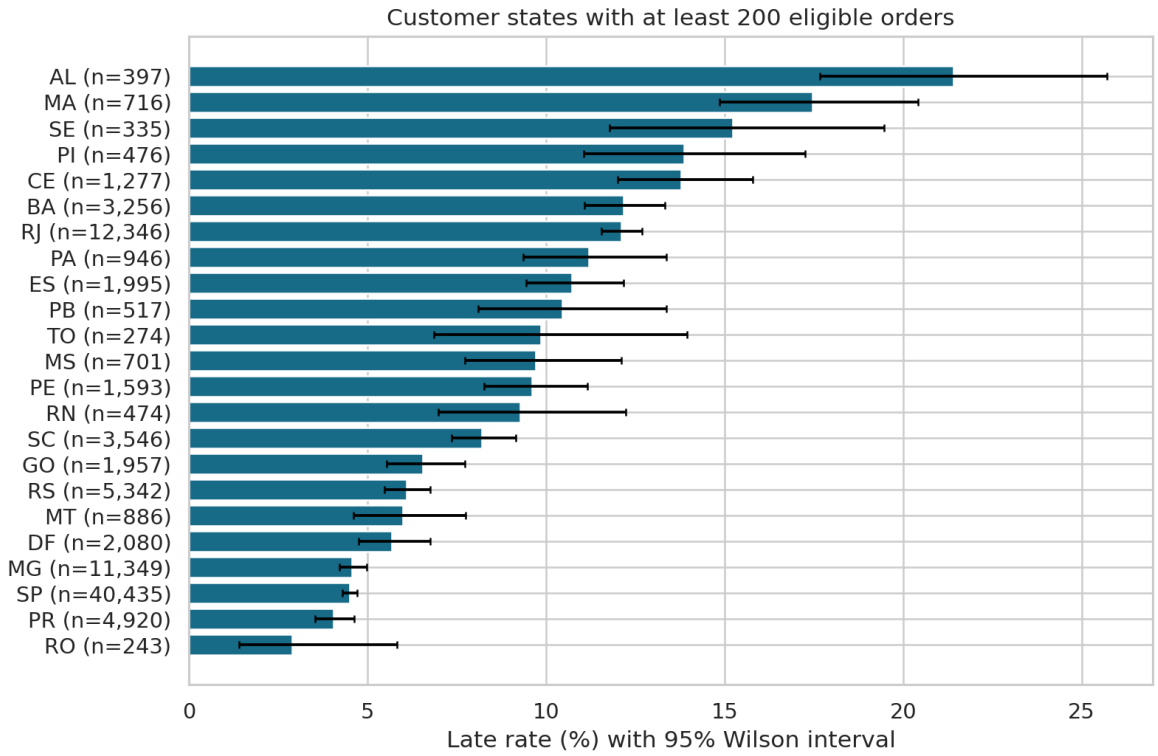


استخدمنا عينة ثابتة من 4,000 طلب لرؤية المدة الفعلية مقابل المخططة. الفعلية أيام منقضية، والمخططة أيام تقويمية، فيختلف المقياسان قرب نهاية اليوم. المدة الفعلية تساعد على شرح ما حصل فقط ولا تدخل التنبؤ.

هل اختلف التأخر بين الولايات

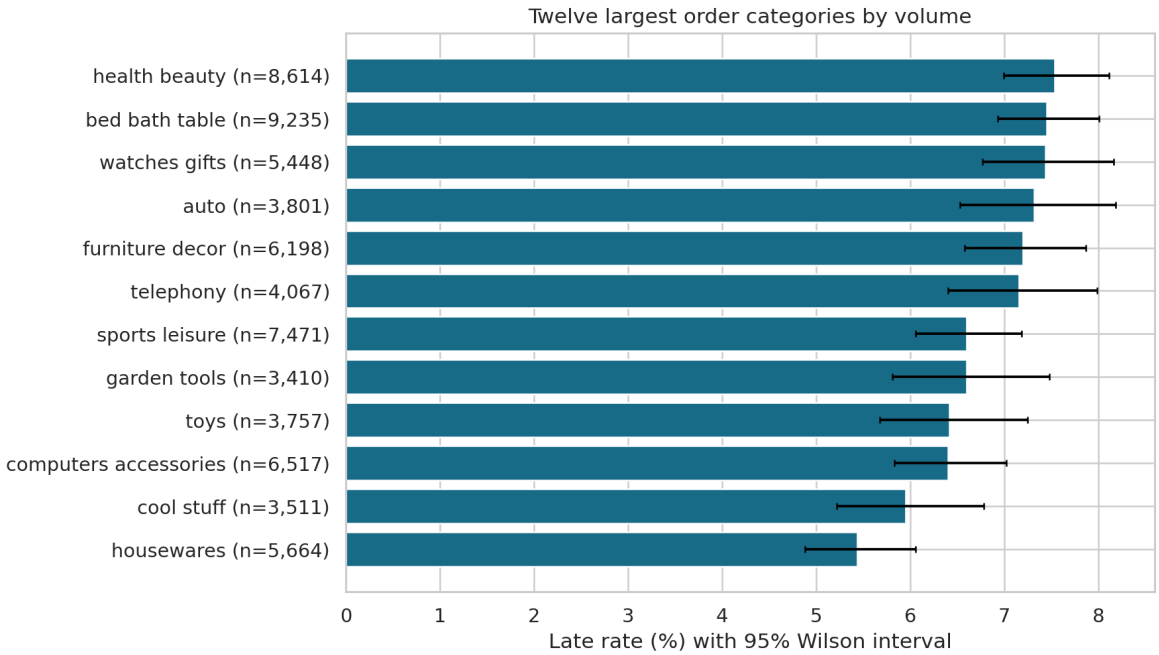
المسار	العينة	التأخر	95% **Wilson** حدا
All interstate	61,631	8.06%	7.85% / 8.28%
All same state	34,516	4.52%	4.31% / 4.75%
Mixed	247	0.40%	0.07% / 2.26%

التأخر 8.06% عندما جاءت كل العناصر من خارج ولاية العميل، مقابل 4.52% عند تطابق الولاية لجميع العناصر. المجموعة المختلطة صغيرة، 247 طلباً، فلا نعتبرها مساراً أفضل بثقة. الولاية ليست المسافة الفعلية، وقد تتداخل الفروق مع الفئات والوعود.



عرضنا الولايات التي تضم 200 طلب مؤهل على الأقل مع حجم كل عينة ونطاق Wilson. بلغت النسبة 12.11% في RJ و4.50% في SP. المقارنة تحدد ما يستحق المتابعة، ولا تثبت سبباً أو جودة شركة نقل بعينها. جميع الولايات موجودة في state_late.csv.

هل اختلف التأخر حسب المنتجات وحجم الطلب

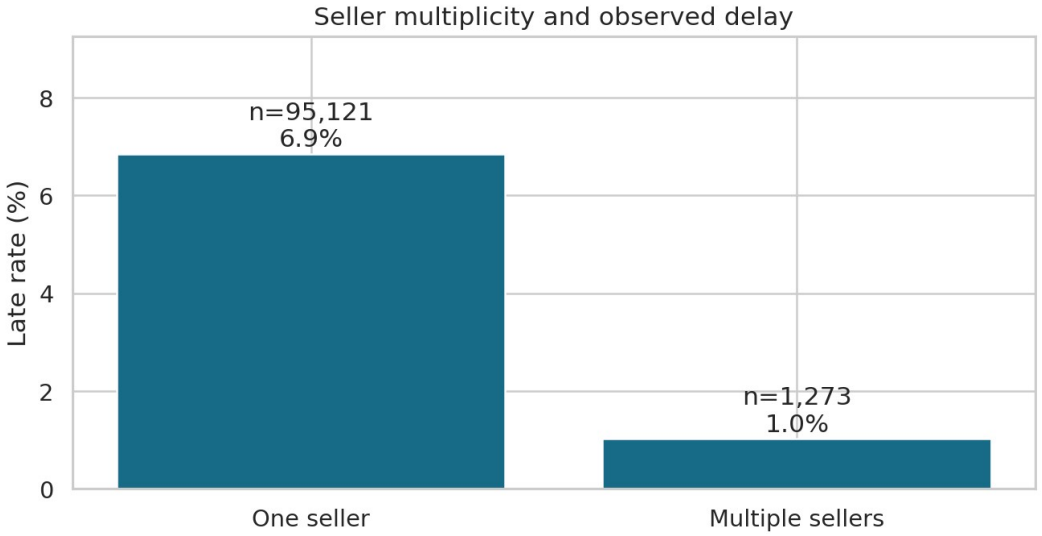


اخترنا أكبر 12 فئة عدداً حتى لا تقودنا عينة صغيرة إلى استنتاج كبير. النسبة 7.53% للصحة والجمال و7.45% لمستلزمات السرير والحمام و6.60% للرياضة والترفيه. نحتاج إلى مراعاة مكان العميل وحجم الطلب والموعد المتوقع قبل تفسير سبب الفرق.

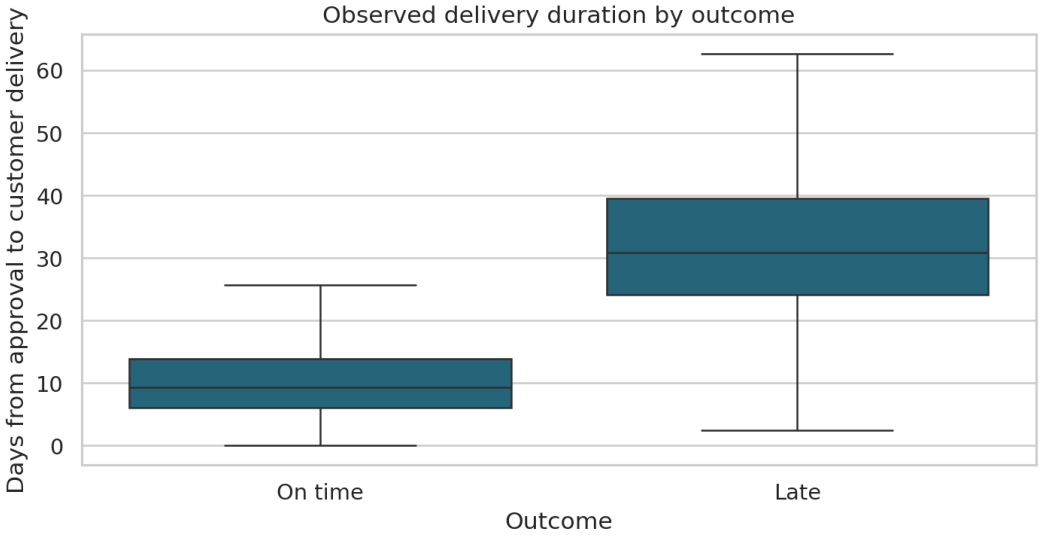
عدد العناصر	العينة	التأخر	95% Wilson حدا
1	86,766	6.94%	6.77% / 7.11%
2	7,387	5.36%	4.87% / 5.90%
3-4	1,799	4.84%	3.94% / 5.93%
5+	442	5.88%	4.05% / 8.48%

لم ترتفع النسبة بشكل منتظم مع عدد العناصر. الطلبات ذات خمسة عناصر فأكثر أقل عدداً بكثير من طلبات العنصر الواحد، فلا نعمم منها. كما أن عدد العناصر لا يساوي عدد الطرود الفعلي غير المسجل.

ما الذي ظهر في الطلبات متعددة البائعين

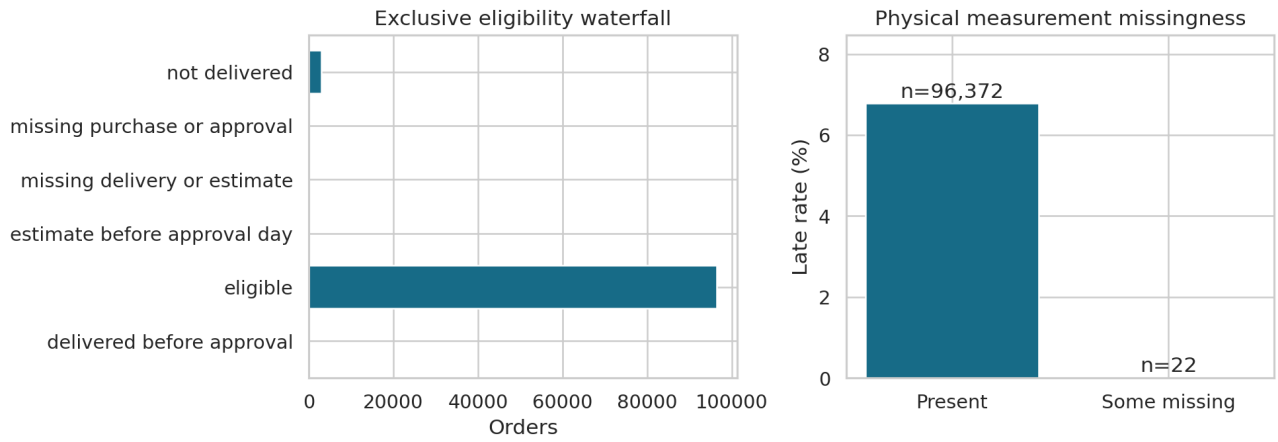


تأخر 6.85% من الطلبات ذات البائع الواحد، مقابل 1.02% لمتعددة البائعين. النتيجة لا تثبت أن زيادة البائعين تحسن التسليم؛ ينبغي فحص اختلاف الوعد وتركيب المنتجات بين المجموعتين أولاً.



استغرقت الطلبات المتأخرة مدة أطول للوصول. أخفيت النقاط البعيدة في هذا الرسم لتسهيل القراءة ولم تحذف من البيانات. جزء من الفرق متوقع من تعريف التأخر نفسه، لذلك لا نعد الرسم اختباراً مستقلاً لنجاح التنبؤ.

ما أثر النواقص والاستبعادات

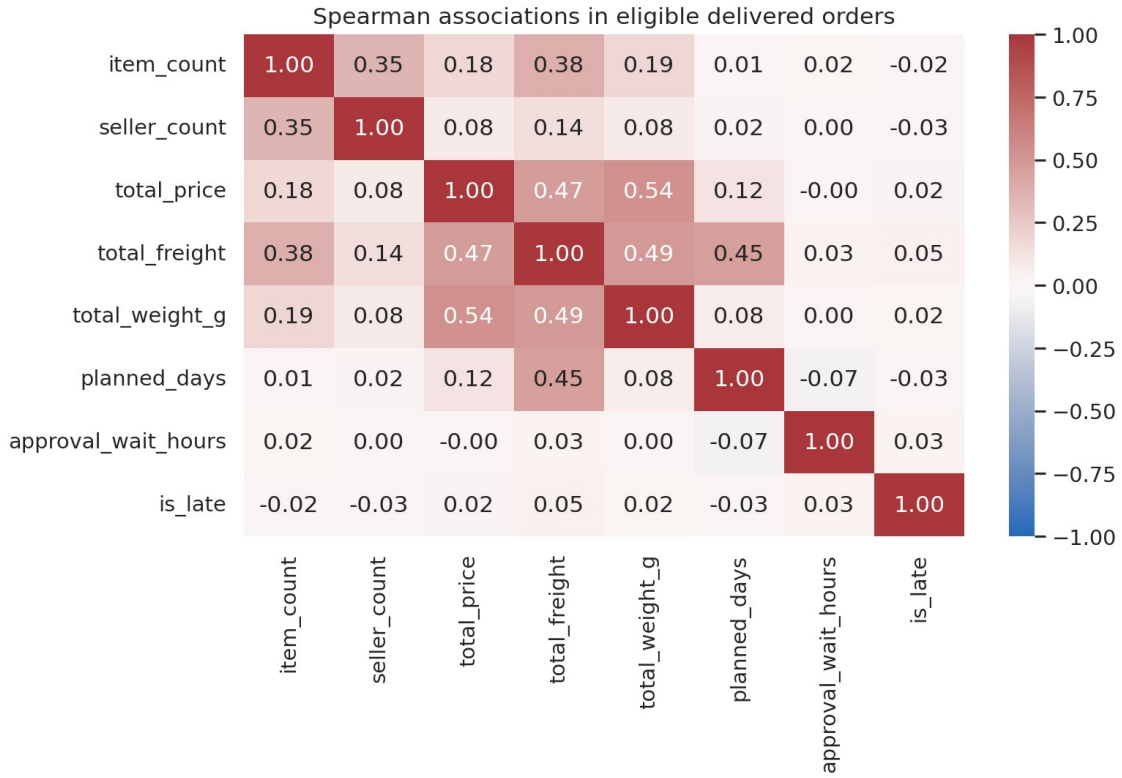


الرسم الأيسر من جميع الطلبات، والأيمن من المؤهلين فقط. لم يتأخر أي من الطلبات الـ22 التي فقدت بعض القياسات الفيزيائية؛ العدد صغير جداً للجزم بانعدام الخطر، والحد الأعلى لنطاق Wilson يقارب 14.9%.

الولاية	كل الطلبات	المؤهلون	الاستبعاد
SP	41,746	40,435	3.14%
RJ	12,852	12,346	3.94%
MG	11,635	11,349	2.46%
RS	5,466	5,342	2.27%
PR	5,045	4,920	2.48%
SC	3,637	3,546	2.50%

هذه أكبر ست ولايات، والجدول الكامل محفوظ. استبعاد الملغى وغير المسلم يجعل استنتاجاتنا مشروطة بالطلبات التي انتهت بتسليم فعلي وتواريخ صالحة لا نخلط هذا المجتمع مع كل طلب أنشئ في المتجر.

ما العلاقات التي ظهرت بين المتغيرات



تظهر خريطة Spearman ارتباطات بين السعر والشحن والوزن ومؤشرات حجم الطلب. ارتباط كل خاصية بالتأخر ضعيف عموماً، ولا ينفي ذلك وجود علاقة غير خطية أو تفاعل بين المتغيرات. الارتباط لا يثبت السببية ولا استقلال فائدة كل خاصية.

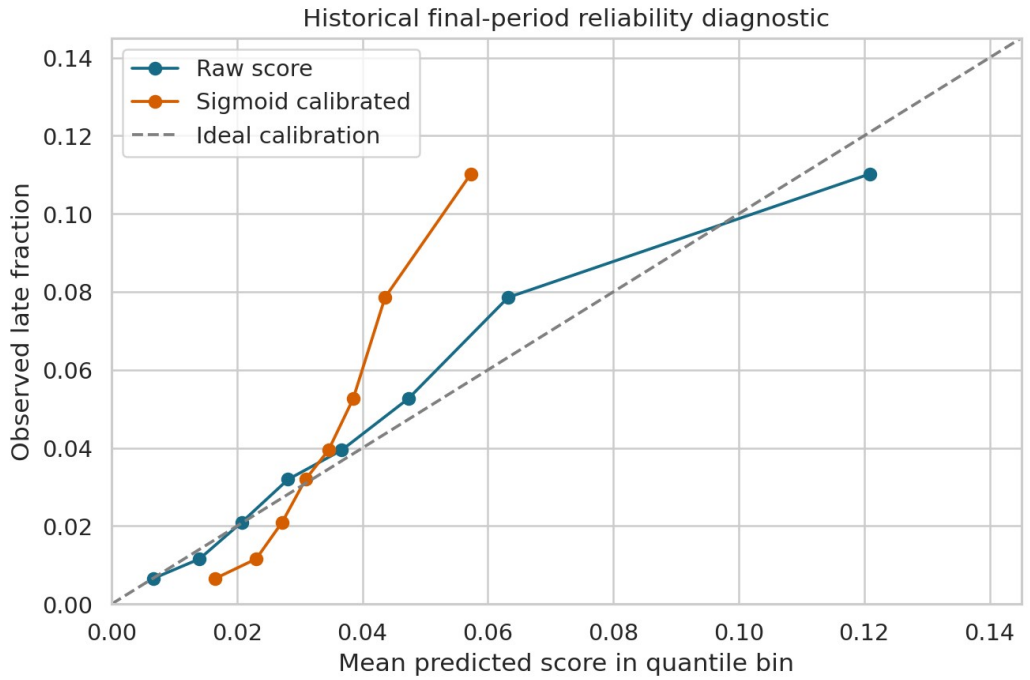
NumPy	الاستخدام
np.divide	نسبة الشحن وحساب F1 دون قسمة على صفر
np.sqrt	حدود Wilson حسب المعدل وحجم العينة
np.select	فئات المسار وأنواع أخطاء التنبؤ
np.log1p وsin وcos	تمثيل القيم الكبيرة والوقت الدوري
default_rng	إعادة معاينة الاختبار ببذرة ثابتة

استخدمنا Pandas أيضاً لإنشاء pivot_table يجمع معدل التأخر وعدد الطلبات حسب ولاية العميل والمسار. الجداول تحفظ الأرقام التي بنيت منها الرسوم، لتكون المراجعة ممكنة بعيداً عن شكل الرسم وحده.

كيف عايرنا الدرجات واخترنا العتبة

جزء التحقق	الطلبات	المتأخرة	النسبة
calibration	3,248	125	3.85%
threshold	3,743	272	7.27%

ملاءمة النموذج الأساسي من التدريب فقط. استخدمنا النصف الأول من كانون الثاني 2018 لمعايرة sigmoid، والنصف الثاني لاختيار أعلى F1. الجزآن منفصلان ولا يدخل أي منهما في ملاءمة النموذج الأساسي. استخدمت نتائج التحقق بعد اكتمالها وقبل أيار؛ هذا فصل لتطوير الاختيار، وليس محاكاة توقع حي لكل يوم من كانون الثاني.



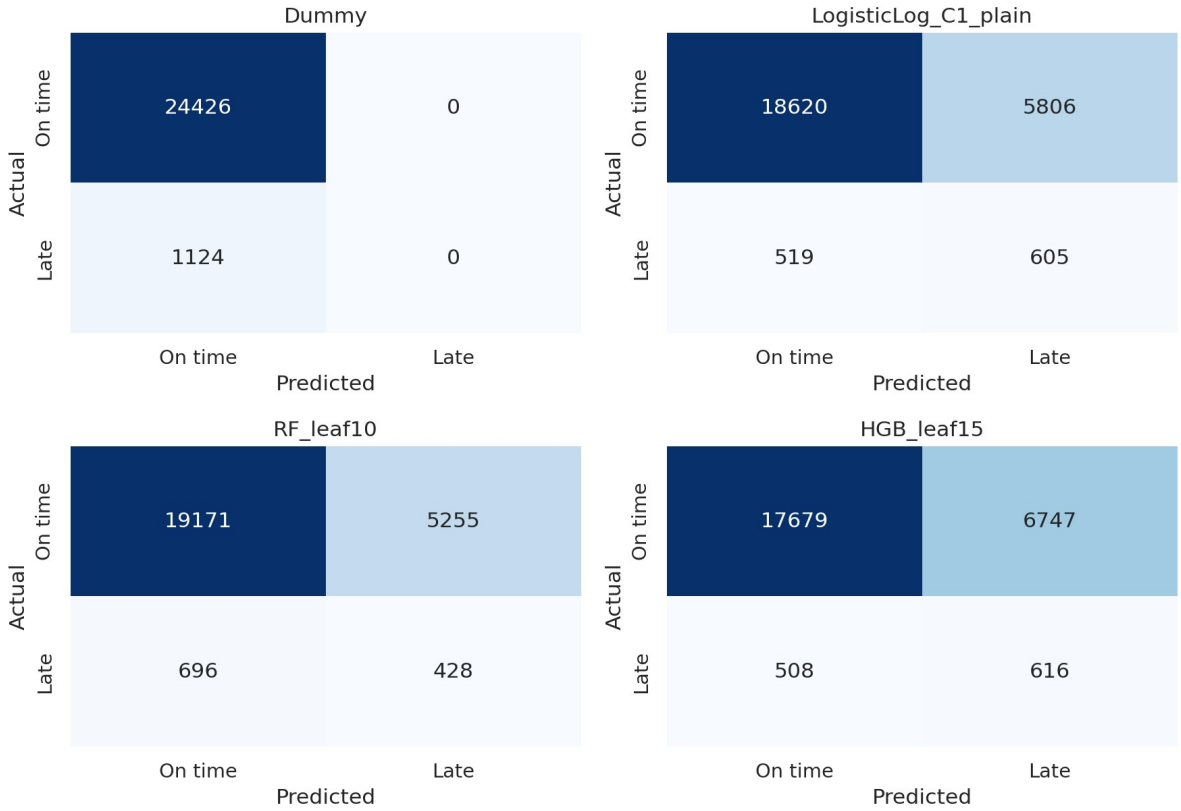
الدرجة	Brier	متوسط الدرجة	التأخر الفعلي
raw	0.0413	4.22%	4.40%
calibrated	0.0415	3.40%	4.40%

ثبتت العتبة عند 0.040622 من التحقق فقط. يوضح الرسم جودة المعايرة في الفترة التاريخية النهائية للتشخيص، ولا يستخدم لتغييرها. Brier الأصغر أفضل. في هذه الفترة لم تحسن المعايرة هذا المقياس؛ بقيت خطوة مقررة قبل الاختبار ولم نعكس القرار بعد رؤية نتائجه. المعايرة لا تضمن استمرار الاحتمالات نفسها عند تغير التشغيل.

ماذا حدث عند تجربة الفترة الأحدث

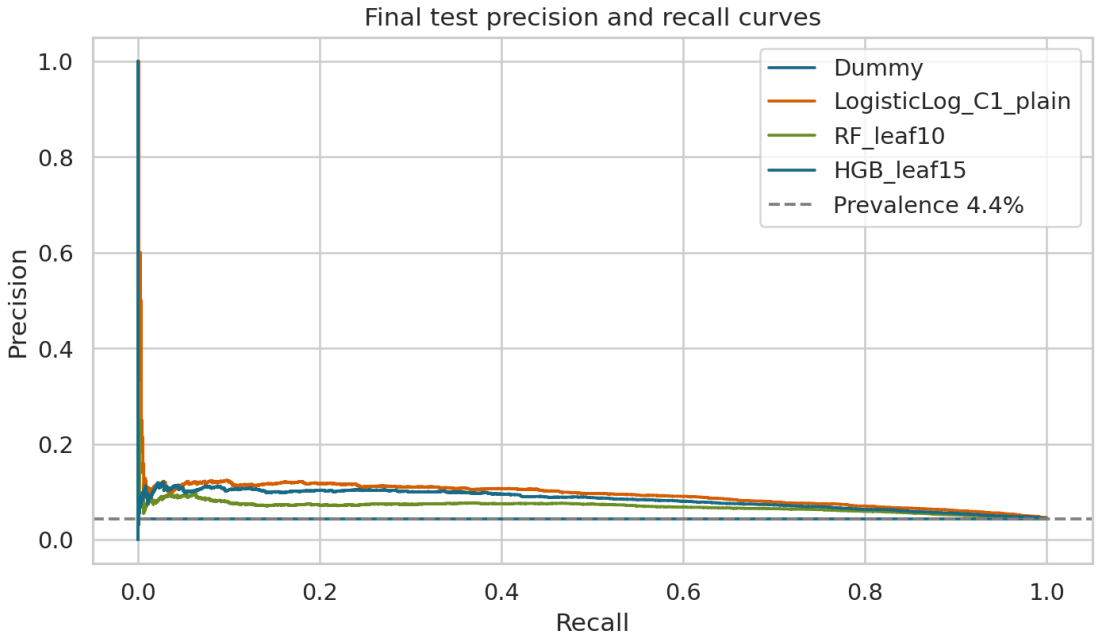
النموذج	Accuracy	Precision	Recall	F1	AP
Dummy	0.9560	0.0000	0.0000	0.0000	0.0440
LogisticLog_C1_plain	0.7524	0.0944	0.5383	0.1606	0.0951
RF_leaf10	0.7671	0.0753	0.3808	0.1258	0.0690
HGB_leaf15	0.7160	0.0837	0.5480	0.1452	0.0838

الفترة النهائية 25,550 طلباً منها 1,124 متأخراً. اختير إعداد واحد لكل عائلة من المقارنة الزمنية، ثم ثبتت معايرته وعتبته من التحقق. جميع النماذج تقاس على الطلبات نفسها لا نعيد اختيار الفائز من هذا الجدول.



اكتشف النموذج المختار 605 متأخراً وفاته 519، وأطلق 5,806 إنذاراً خاطئاً. أي أن 90.56% من الإنذارات خاطئة. هذا يوضح عبء المتابعة إلى جانب الاستدعاء 53.83%؛ جودة المنهج لا تعني أن النموذج أصبح مناسباً للتشغيل الآلي.

كيف تتغير النتيجة عند تغيير حجم المتابعة



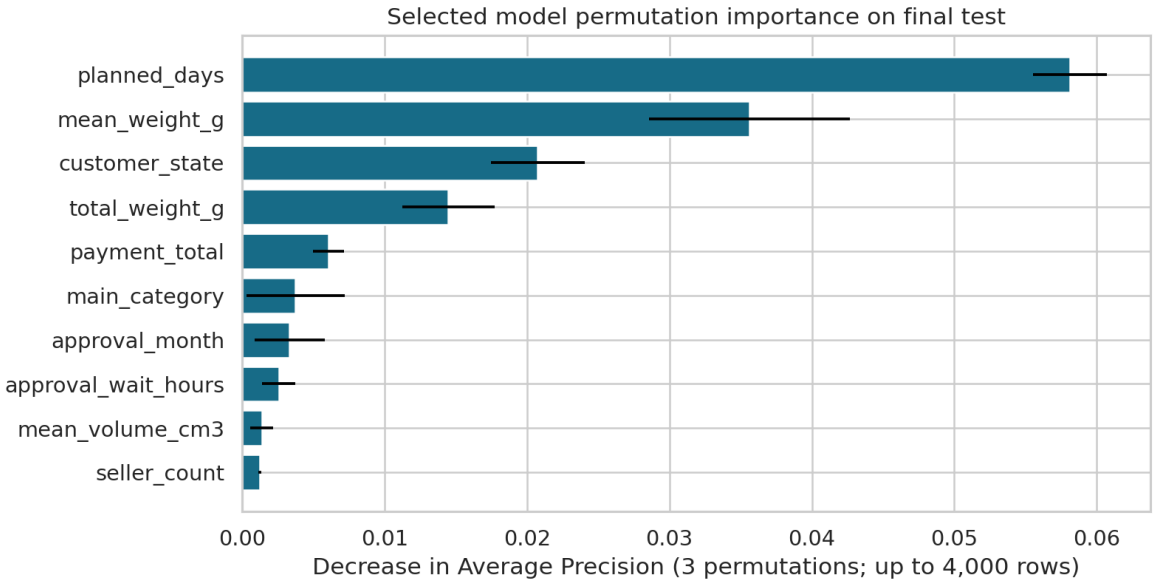
المنحنى يوضح التبادل بين الإحكام والاستدعاء، والخط المرجعي انتشار الفئة. الرسم تشخيص بعد تثبيت الاختيار، ولا نعتمد عليه لتعديل العتبة على الاختبار.

المقياس	القيمة	فاصل شرطي 95%
precision	0.0944	0.0869 / 0.1014
recall	0.5383	0.5095 / 0.5680
f1	0.1606	0.1492 / 0.1711
average_precision	0.0951	0.0855 / 0.1050

أعلى نسبة للمتابعة	طلبات	متأخرة مكتشفة	الإحكام
1.00%	256	29	11.33%
5.00%	1,278	144	11.27%
10.00%	2,555	284	11.12%
20.00%	5,110	519	10.16%

جدول المتابعة يشرح ترتيب النموذج عند ميزانيات افتراضية، ولا يختار سياسة تشغيل من الاختبار. الفواصل من 300 إعادة معاينة مع نموذج ثابت؛ لا تشمل عدم يقين اختيار النموذج أو الاعتماد بين طلبات البائع والعميل أو التغير الزمني.

ما المعلومات المفيدة وأين تركز الخطأ



أبرز المعلومات في عينة التفسير: planned_days، mean_weight_g، customer_state، total_weight_g. خلطنا خاصية واحدة على الصفوف نفسها وقسنا انخفاض AP بثلاث محاولات وعلى عينة حتى 4,000 طلب. الأهمية تشخيصية، وقد تتشارك الخصائص المترابطة فائدتها؛ لا تفسر كسبب مباشر للتأخر.

الوعد بالأيام	العينة	FP	FN	Precision	Recall
0-7	1,583	951	40	17.88%	83.81%

الوعد بالأيام	العينة	FP	FN	Precision	Recall
8-14	5,420	1,806	140	7.15%	49.82%
15-21	6,809	1,424	177	8.95%	44.16%
22-30	7,058	1,294	125	7.37%	45.18%
31+	4,680	331	37	4.61%	30.19%

لا تقتصر المراجعة على أعداد أخطاء الولايات؛ حفظنا معدلات الأخطاء أيضاً حسب نافذة الوعد وحجم الطلب والفئة. أحجام المجموعات مهمة، والمعدل من عينة صغيرة لا يصلح وحده لاقتراح قاعدة جديدة.

أمثلة فعلية على أخطاء النموذج

رقم مختصر	الخطأ	الولاية	الوعد	الدرجة	الحقيقة
cf4659487be5	FP	PB	27	0.1280	0
7e225c7be8d2	FP	AL	19	0.1276	0
67c8c2016dda	FP	AL	21	0.1164	0
580e21d2e462	FN	MG	19	0.0154	1
6325af88a061	FN	MG	33	0.0155	1
6a0723108172	FN	RJ	41	0.0170	1

اخترنا ثلاثة أمثلة من كل نوع لعرض طريقة المراجعة: FP طلب أطلقنا له إنذاراً لكنه وصل في موعده، وFN طلب متأخر لم يطلق له إنذار. رقم الطلب الكامل والخصائص محفوظة في error_examples.csv، ويمكن تتبعه إلى صفه الخام.

الحالات الأعلى درجة بين FP تكشف الثقة الزائدة في إنذارات غير صحيحة. أما أدنى درجات FN فتظهر طلبات لم تفسر معلومات الاعتماد خطرها جيداً. يمكن وصف الولاية والوعد والخصائص، لكن لا نختلق سبباً مثل نفاد المخزون أو خطأ شركة النقل، لأن تلك التفاصيل غير متاحة.

المراجعة لا تحذف هذه الحالات ولا تغير عتبتها بعد رؤيتها. فائدتها تحديد ما يجب اختباره لاحقاً: معايرة أكثر ثباتاً، معلومات تشغيلية عند الاعتماد، أو تقييم حسب مجموعات ذات عينات كافية. تغيير النموذج بناء عليها يحتاج دورة تطوير موثقة وتقييماً جديداً.

ما بقي محدوداً

عدد النماذج والإعدادات أوسع من النسخة الأولى لكنه ما زال بحثاً محدوداً، وثلاث فترات لا تغطي كل أنواع التغير لا توجد تكلفة فعلية للمتابعة أو دراسة أثر تدخل. وتحسين الدرجة التاريخية وحده لا يثبت أن المشروع سيمنع التأخر أو يحقق ربحاً.

ما الذي تحسن وما الذي لا نعد به

أصلحنا اختيار الصفوف عند الحدود باستخدام فترات اعتماد كاملة وفاصل موحد، وأضفنا ثلاث مقارنات زمنية وفصل المعايرة عن ضبط العتبة. الشفرة أوضح، والإعدادات محفوظة، ويمكن فحص المجاميع والأهداف والنتائج المحفوظة آلياً. هذه تحسينات في صحة التجربة وقابليتها للمراجعة.

نتيجة النموذج المختار تبقى 9.44% إحكاماً و53.83% استدعاء وAP=0.0951. نعرض الأرقام كما ظهرت دون إعلان نجاح تشغيلي لمجرد أن المشروع استوفى المتطلبات. إن كانت الإنذارات كثيرة، يحتاج فريق العمل إلى تجربة تكلفة ومنفعة قبل اعتمادها.

المقياس	النسخة المستلمة	إعادة التشغيل الحالية
precision	0.0944	0.0944
recall	0.5383	0.5383
f1	0.1606	0.1606
average_precision	0.0951	0.0951
fp	5,806	5,806
fn	519	519

هذه مقارنة وصفية مع النسخة المستلمة، وليست اختباراً مستقلاً. وانخفاض الإنذارات الخاطئة في تلك النسخة مقارنة بالأقدم ترافق مع انخفاض الاستدعاء. نعرض الجانبين ولا نسميه تحسناً شاملاً. الاختيار الحالي مبني على التطوير فقط مهما كانت نتيجة هذه المقارنة.

المجتمع مشروط بالطلبات المسلمة وتواريخها الصالحة، ولا يشمل خطر الإلغاء أو النتيجة المجهولة. توفر تفاصيل الدفع والمنتجات والموعد عند الاعتماد افتراض يسمح به التكليف. الولاية ليست مسافة والوزن والحجم ليسا قياساً مؤكداً للطرد. كما لا نملك سجلاً كاملاً لتغير الحالات أو المخزون أو حركة الناقل أو الطقس.

سبق الاطلاع على نتائج الفترة النهائية في النسخة الأولى وفي مرور التطوير الموثق. اختيار النسخة الحالية يستخدم المقارنة الزمنية والتحقق فقط، لكن ذلك لا يعيد للفترة صفة الاختبار غير المشاهد. لذلك نحتاج بيانات جديدة أو تقييماً خارجياً مستقلاً قبل ادعاء ثبات التحسن.

ما نوصي به لاحقاً

الأولوية جمع معلومات تشغيلية موثوقة في لحظة الاعتماد، ومتابعة تغير النسب والمعايرة عبر الزمن، ثم اختيار سياسة إنذار وفق ميزانية فعلية لا نغير تعريف الهدف لإظهار نتيجة أعلى، ولا نعوض ضعف المدخلات باستخدام معلومات حدثت بعد التنبؤ.

التشغيل وعمل الفريق والمصادر

يشرح README.md إعداد Python وتشغيل run_pipeline.py والاختبارات. يحدد config.json الفترات والمعايير، ويحتفظ outputs/tables بالتدقيق والتجارب والتنبؤات. يعيد docs/build_report.py التقرير من النتائج الحالية، وتقرأ جداول النماذج آلياً؛ الوصف النصي للبيانات مراجع على بصمات الملفات الأصلية المرفقة. سجلات التجارب القديمة محفوظة لتوضيح تاريخ المراجعة.

تشمل الاختبارات المفاتيح والربط والمجاميع، والتسليم في اليوم المتوقع واليوم التالي والنواقص، والحقول المحظورة، وعضوية الفترات المستقلة عن سرعة الوصول، ووقت معرفة النتيجة، وتطابق التنبؤات مع النموذج المحفوظ، وإنشاء المجلدات عند غيابها. شغّل مهند المشروع على Windows مع Python 3.12.10 خلال 61.6 ثانية،

ونجحت الاختبارات الـ37 خلال 13.184 ثانية. حُفظت الإصدارات في requirements-windows-tested.txt؛ نجح التشغيل بعد تثبيت SciPy 1.16.3.

احتفظنا بسجل Git التاريخي دون إعادة كتابة أسماء مؤلفيه أو تواريخه، ثم وثّقنا التعديلات اللاحقة بتواريخها الحقيقية. يشمل ذلك التحديث cb85496 المرتبط باعتماديات Windows. وفي 9 تشرين الثاني 2026 رُفع الفرع main إلى مستودع المشروع: https://github.com/wbmohandalshaar-pixel/DPD601-Olist-Delivery. يدل سجل Git على تطور الملفات، بينما يعتمد توزيع المسؤوليات على تأكيد الفريق والأدلة المرفقة.

توثيق المساهمات

توزّع العمل بين أعضاء الفريق بحسب ما أكده الفريق: تولّى مهند التكامل والتشغيل وإدارة Git، وبيان تجهيز البيانات وتنظيفها والتحليل الاستكشافي، ومازن بناء النماذج وتقييم نتائجها، ومحمد التقرير والتوثيق ومراجعة الاختبارات. وترد المسؤوليات في TEAM_CONTRIBUTIONS.csv. أما مراجعات كود الزملاء فتحتاج إلى أدلتها الفردية وفق التكليف.

المصادر والترخيص

[1] ورقة تكليف F25 DPD601، الدكتورة دعاء قرضاب، Ecommerce_Project_Assignment_DPD601_F25_PR.pdf، النسخة المقدمة من الطالب.

[2] Olist, & Sionek, A. (2018). Brazilian E-Commerce Public Dataset by Olist. Kaggle. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

[3] ترخيص البيانات CC BY-NC-SA 4.0 كما ورد في التكليف. يلزم الإسناد والاستخدام غير التجاري ومشاركة التعديلات وفق الترخيص نفسه. https://creativecommons.org/licenses/by-nc-sa/4.0/